

CÁLCULO NUMÉRICO

Aula 14

Ajuste de Curvas



AJUSTE DE CURVAS

Introdução

- Em geral, experimentos geram uma **gama de dados** que devem ser analisados para a criação de um **modelo**.
- Obter uma **função** matemática que **represente** (ou que ajuste) os dados permite fazer simulações do processo de forma confiável, reduzindo assim repetições de experimentos que podem ter um **custo alto**.

Introdução

- Em geral, **não é aconselhável** usar interpolação polinomial quando:
 - ▣ Deseja-se **extrapolar**, fazer previsões em regiões fora do intervalo considerado;
 - ▣ Os dados tabelados são **resultados de experimentos**, onde **erros** na obtenção destes resultados podem influenciar a sua qualidade.

Introdução

O objetivo é obter uma função que seja uma “boa aproximação” e que permita **extrapolações** com alguma margem de segurança.

Introdução

- A escolha das funções pode ser feita:
 - ▣ **Observando o gráfico** dos pontos tabelados;
 - ▣ Baseando-se em **fundamentos teóricos** do experimento que forneceu a tabela ou;
 - ▣ Através de uma **função já conhecida**.

Introdução

O Método dos Mínimos Quadrados é um método bastante utilizado para **ajustar** uma determinada quantidade de pontos e **aproximar funções**.

MÉTODO DOS MÍNIMOS QUADRADOS

Método dos Mínimos Quadrados

- O Método dos Mínimos Quadrados consiste em escolher os α_k ($k = 1, 2, \dots, n$) de tal forma que:

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x) \quad (1)$$

se aproxime ao máximo de $f(x)$.

onde: $f(x)$ fornece os **pontos exatos**;
 $g(x)$ fornece os **pontos estimados**.

Método dos Mínimos Quadrados

- O Método dos Mínimos Quadrados consiste em escolher os α_k ($k = 1, 2, \dots, n$) de tal forma que a **soma dos quadrados dos desvios** seja mínima.


$$E = \sum_{k=1}^m [f(x_k) - \phi(x_k)]^2 \quad (2)$$

Método dos Mínimos Quadrados

x_i	$f(x_i)$
1	2
2	4
3	3
4	5

$f(x)$

$$\phi(x) = 0,8x + 1,5$$



Método dos Mínimos Quadrados

- Observe que, se o modelo ajustar exatamente aos dados, o mínimo da função:

$$E = \sum_{k=1}^m [f(x_k) - \phi(x_k)]^2$$


será zero e, portanto, a **interpolação** é um **CASO ESPECIAL** dentro do método dos quadrados mínimos.

Método dos Mínimos Quadrados

x_i	$f(x_i)$
1	2
2	4
3	3
4	5

$f(x)$

$$\phi(x) = x^3 - 7,5x^2 + 17,5x - 9$$



Método dos Mínimos Quadrados

- Dado um conjunto de pontos $(x_k; f(x_k))$, $k = 0, 1, 2, \dots, m$
(f dada por **TABELA DE VALORES**)
- O problema de ajuste de curvas consiste em encontrar funções $g_k(x)$, tais que o desvio em cada ponto k , definido por (2) seja mínimo, ou seja:

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

se aproxime ao máximo de $f(x)$.

Método dos Mínimos Quadrados

- **COMO ESCOLHER $g_k(x)$????**
- A escolha das funções $g_k(x)$ depende do gráfico dos pontos, chamado de **DIAGRAMA DE DISPERSÃO**, através do qual pode-se visualizar o tipo de curva que melhor se ajusta aos dados.




AJUSTE LINEAR

Ajuste Linear

x_i	$f(x_i)$
1	2
2	4
3	3
4	5

$f(x)$

$$\phi(x) = 0,8x + 1,5$$



Ajuste Linear

- Como pode ser observado no gráfico anterior, uma possível aproximação seria através de uma **função linear** do tipo:

$$\phi(x_k) = \alpha_0 + \alpha_1 x_k \quad (3)$$

- Assim o objetivo é determinar os valores de α_0 e α_1 , que minimizem:

$$E = \sum_{k=1}^m [y_k - (\alpha_0 + \alpha_1 x_k)]^2$$

Ajuste Linear

- Para que E seja mínimo é necessário que:

$$\frac{\partial E}{\partial \alpha_0} = 0 \quad (4)$$

$$\frac{\partial E}{\partial \alpha_1} = 0 \quad (5)$$

Ajuste Linear

- As equações (4) e (5) simplificam-se nas EQUAÇÕES NORMAIS:

$$\alpha_0 m + \alpha_1 \sum_{k=1}^m x_k = \sum_{k=1}^m y_k \quad (6)$$

$$\alpha_0 \sum_{k=1}^m x_k + \alpha_1 \sum_{k=1}^m x_k^2 = \sum_{k=1}^m x_k y_k \quad (7)$$

- Resolvendo este sistema de equações, encontramos os valores de α_0 e α_1 .

EXEMPLO 1

- Considerando os dados da Tabela 1, e através do gráfico gerado, pode-se definir que tipo de curva melhor se ajusta aos dados.

Tabela 1

x_k	1	2	3	4	5	6	7	8	9	10
y_k	1,3	3,5	4,2	5,0	7,0	8,8	10,1	12,5	13,0	15,6

EXEMPLO 1




Figura 1. Diagrama de Dispersão para os dados da Tabela 1

EXEMPLO 1

- Considerando a Tabela 1, e os dados necessários para as equações (8) e (9), a Tabela 2 pode ser construída:

k	x_k	y_k	x_k^2	$x_k y_k$
1	1	1,3	1	1,3
2	2	3,5	4	7,0
3	3	4,2	9	12,6
4	4	5,0	16	20,0
5	5	7,0	25	35,0
6	6	8,8	36	52,8
7	7	10,1	59	70,7
8	8	12,5	64	100,0
9	9	13,0	81	117,0
10	10	15,6	100	156,0
Σ	55	81	385	572,4

EXEMPLO 1

- Considerando os dados da Tabela 2, os parâmetros α_0 e α_1 podem ser calculados como:

$$\alpha_0 = -0,360$$

$$\alpha_1 = 1,538$$

- Assim a reta a ser ajustada é determinada por:

$$y = 1,538x - 0,360$$

EXEMPLO 1

- Na Figura 2, pode-se observar o ajuste através da reta:




Figura 2. Ajuste linear



AJUSTE POLINOMIAL

Ajuste Polinomial

- O processo usado para o ajuste linear pode ser estendido para ajuste polinomial.
- Assim, uma função polinomial de grau n é dada por:

$$P_n(x) = \alpha_n x^n + \alpha_{n-1} x^{n-1} + \cdots + \alpha_1 x + \alpha_0$$

- O objetivo é minimizar o erro:

$$E = \sum_{k=1}^m [y_k - P_n(x_k)]^2$$

Ajuste Polinomial

- Como no caso linear, para que E seja minimizado é necessário que:

$$\frac{\partial E}{\partial \alpha_j}(\alpha_0, \alpha_1, \dots, \alpha_n) = 0 \quad \text{para cada } j = 0, 1, \dots, n.$$

- Isto fornece as $n+1$ equações normais nas $n+1$ incógnitas α_j :

$$\sum_{i=0}^n \alpha_i \sum_{k=1}^m x_k^{j+i} = \sum_{k=1}^m x_k^j y_k \quad \text{para cada } j = 0, 1, \dots, n.$$

Ajuste Polinomial

$$\alpha_0 m + \alpha_1 \sum_{k=1}^m x_k + \alpha_2 \sum_{k=1}^m x_k^2 + \cdots + \alpha_n \sum_{k=1}^m x_k^n = \sum_{k=1}^m y_k$$

$$\begin{array}{ccccccc} \alpha_0 \sum_{k=1}^m x_k & + & \alpha_1 \sum_{k=1}^m x_k^2 & + & \alpha_2 \sum_{k=1}^m x_k^3 & + \cdots + & \alpha_n \sum_{k=1}^m x_k^{n+1} = \sum_{k=1}^m y_k x_k \\ & & \vdots & & & & \vdots \end{array}$$

$$\alpha_0 \sum_{k=1}^m x_k^n + \alpha_1 \sum_{k=1}^m x_k^{n+1} + \alpha_2 \sum_{k=1}^m x_k^{n+2} + \cdots + \alpha_n \sum_{k=1}^m x_k^{2n} = \sum_{k=1}^m y_k x_k^n$$


EXEMPLO 2

- Ajustar os dados da Tabela 3 com um polinômio de grau dois utilizando o método dos mínimos quadrados.

Tabela 3

k	x_k	y_k
1	0,00	1,0000
2	0,25	1,2840
3	0,50	1,6487
4	0,75	2,1170
5	1,00	2,7183

EXEMPLO 2



EXEMPLO 2

k	x_k	y_k	x_k^2	x_k^3	x_k^4	$x_k y_k$	$x_k^2 y_k$
1	0,00	1,0000	0,0000	0,0000	0,0000	0,0000	0,0000
2	0,25	1,2840	0,0625	0,1563	0,0039	0,3210	0,0803
3	0,50	1,6487	0,2500	0,1250	0,0625	0,8244	0,4122
4	0,75	2,1170	0,5625	0,4219	0,3164	1,5878	1,1908
5	1,00	2,7183	1,0000	1,0000	1,000	2,7183	2,7183
Σ	2,50	8,7680	1,875	1,5625	1,3828	5,4514	4,4015

EXEMPLO 2

- Para este problema, $n = 2$, $m = 5$ e as três equações normais são:

$$\left\{ \begin{array}{l} 5,0\alpha_0 + 2,5\alpha_1 + 1,875\alpha_2 = 8,7680 \\ 2,5\alpha_0 + 1,875\alpha_1 + 1,5625\alpha_2 = 5,4514 \\ 1,875\alpha_0 + 1,5625\alpha_1 + 1,3828\alpha_2 = 4,4015 \end{array} \right.$$

- Resolvendo o sistema, obtêm-se:

$$\alpha_0 = 1,0051$$

$$\alpha_1 = 0,8647$$

$$\alpha_2 = 0,8432$$

EXEMPLO 2

$$y = 1,0051 + 0,8642x + 0,8437x^2$$




Figura 3. Ajuste polinomial

O erro total

$$E = \sum_{k=1}^5 [y_k - P(x_k)]^2$$
$$= 2,74 \times 10^{-4}$$

é o mínimo que pode ser
obtido usando um polinômio
com grau máximo 2

ATENÇÃO

- Os ajustes realizados até aqui, são lineares em relação aos α_k e não às $g_k(x)$.

$$g_1(x) = e^x$$

se

$$g_2(x) = (1+x)^2$$

$$\phi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x)$$



$$\phi(x) = \alpha_1^2 g_1(x) + e^{\alpha_2} g_2(x)$$



EXEMPLO 3

- Podemos proceder de forma análoga aos casos anteriores.
- Por exemplo, se tivermos:

$$g_0(x) = x$$

$$g_1(x) = \cos(x)$$

$$\text{com, } \phi(x) = \alpha_0 g_0(x) + \alpha_1 g_1(x)$$

EXEMPLO 3

$$\left\{ \begin{array}{l} \alpha_0 \sum_{k=1}^m x_k^2 + \alpha_1 \sum_{k=1}^m x_k \cos x_k = \sum_{k=1}^m x_k y_k \\ \alpha_0 \sum_{k=1}^m x_k \cos x_k + \alpha_1 \sum_{k=1}^m \cos^2 x_k = \sum_{k=1}^m y_k \cos x_k \end{array} \right.$$



AJUSTE NÃO-LINEAR

Ajuste Não-Linear

- Existem casos, onde o **diagrama de dispersão** de uma função indica que os dados devem ser ajustados por uma função **não linear**.
- Ocasionalmente, é apropriado supor que os dados estejam relacionados exponencialmente.
- **Exemplo:** $\phi(x) = ae^{bx}$, para a e b constantes.

A **dificuldade** de aplicação do método dos mínimos quadrados neste caso consiste na tentativa de **minimizar E** .

Ajuste Não-Linear

- Para estes casos, um **PROCESSO DE LINEARIZAÇÃO** deve ser empregado, para que seja possível aplicar o Método dos Mínimos Quadrados.
- Neste caso, podemos proceder da seguinte forma:

Ajuste Não-Linear

- Caso I: **Função Exponencial**

$$\phi(x) = y = ae^{bx}$$

- Aplicando logaritmo em ambos os lados, obtêm-se:

$$\ln(y) = \ln(ae^{bx}) = \ln(a) + bx$$

- Realizando as seguintes substituições:

$$\left\{ \begin{array}{l} Y = \ln(y) \\ \alpha_0 = \ln(a) \\ \alpha_1 = b \\ X = x \end{array} \right.$$

- Obtêm-se: $Y = \alpha_0 + \alpha_1 X$

Ajuste Não-Linear

- Caso II: Função Logarítmica

$$y = a \ln(bx)$$

- Expandindo: $y = a \ln(b) + a \ln(x)$

- Realizando as seguintes substituições:

$$\left\{ \begin{array}{l} Y = y \\ \alpha_0 = a \ln(b) \\ \alpha_1 = a \\ X = \ln(x) \end{array} \right.$$

- Obtêm-se: $Y = \alpha_0 + \alpha_1 X$

Ajuste Não-Linear

- Caso III: **Função Potencial**

$$y = ax^b$$

- Aplicando logaritmo em ambos os lados:

$$\ln(y) = \ln(ax^b) = \ln(a) + \ln(x^b) = \ln(a) + b \ln(x)$$

- Realizando as seguintes substituições:

$$\left\{ \begin{array}{l} Y = \ln(y) \\ \alpha_0 = \ln(a) \\ \alpha_1 = b \\ X = \ln(x) \end{array} \right.$$

- Obtêm-se: $Y = \alpha_0 + \alpha_1 X$

Ajuste Não-Linear

- Caso IV: **Função Hiperbólica**

$$y = a + \frac{b}{x}$$

- Realizando as seguintes substituições:

$$\left\{ \begin{array}{l} Y = y \\ \alpha_0 = a \\ \alpha_1 = b \\ X = x^{-1} \end{array} \right.$$

- Obtêm-se: $Y = \alpha_0 + \alpha_1 X$

Ajuste Não-Linear

- Usam-se as equações do **Ajuste Linear** para obter α_0 e α_1 :

$$\alpha_0 m + \alpha_1 \sum_{k=1}^m x_k = \sum_{k=1}^m y_k$$

$$\alpha_0 \sum_{k=1}^m x_k + \alpha_1 \sum_{k=1}^m x_k^2 = \sum_{k=1}^m x_k y_k$$

LEMBRE-SE!!!!!!!

Após aplicar o método dos mínimos quadrados, é preciso fazer as **substituições necessárias** para encontrar os parâmetros **a** e **b** da função de aproximação original.

IMPORTANTE

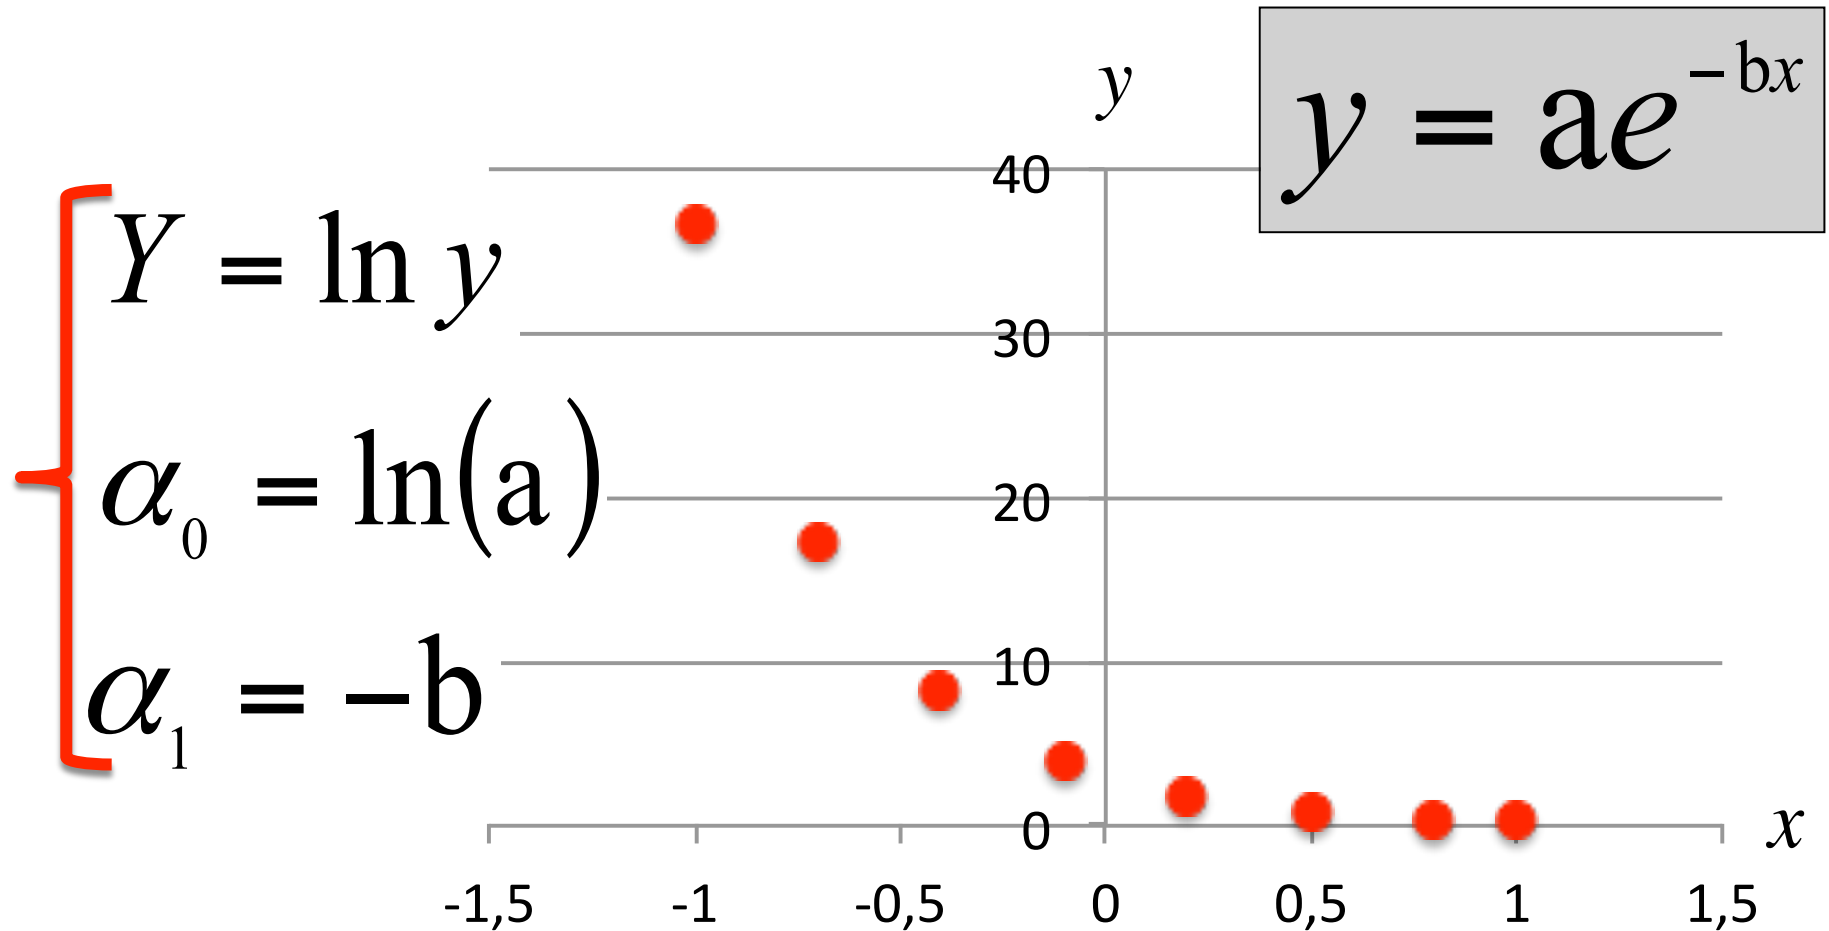
Observe que os parâmetros a e b assim obtidos **não**
são ótimos dentro do critério dos quadrados
mínimos, porque estamos ajustando o problema
linearizado e não o problema **original**.

EXEMPLO 4

- Encontrar uma função que se ajusta aos valores da tabela abaixo:

x	y
-1,0	36,547
-0,7	17,267
-0,4	8,155
-0,1	3,852
0,2	1,82
0,5	0,86
0,8	0,406
1,0	0,246

EXEMPLO 4



EXEMPLO 4

- Como o ajuste será realizado por uma função exponencial é necessário calcular: $Y = \ln y$

k	x_k	y_k	$Y_k = \ln(y_k)$	x_k^2	$x_k Y_k$
1	-1,0	36,547	3,599	1,00	-3,599
2	-0,7	17,264	2,849	0,49	-1,994
3	-0,4	8,155	2,099	0,16	-0,839
4	-0,1	3,852	1,349	0,01	-0,135
5	0,2	1,820	0,599	0,04	0,120
6	0,5	0,860	-0,151	0,25	-0,075
7	0,8	0,406	-0,901	0,64	-0,721
8	1,0	0,246	-1,402	1,00	-1,402
Σ	0,3	69,15	8,041	3,59	-8,645

EXEMPLO 4

$$\alpha_0 = 1,099$$

$$\alpha_1 = -2,5$$

$$\alpha_0 = \ln(a)$$

$$\alpha_1 = -b$$

$$a = 3,001$$

$$b = 2,5$$

$$y = 3,001e^{-2,5x}$$

LEMBRE-SE!!!!!!!

- Os parâmetros α_0 e α_1 que ajustam a função $\varphi(x)$ à função y no sentido dos quadrados mínimos.
- **NÃO** se pode afirmar que os parâmetros a e b (obtidos através de α_0 e α_1) são os que **ajustam $\phi(x)$ à função y** dentro dos critérios dos quadrados mínimos.

Teste de Alinhamento

- Uma vez escolhida uma função não linear em a, b, \dots para ajustar uma função. Uma forma de verificar se a escolha foi razoável é aplicar o **TESTE DE ALINHAMENTO**.

Teste de Alinhamento

- Fazer a “**linearização**” da função não linear escolhida;
- Fazer o **diagrama de dispersão** dos novos dados;
- Se os pontos do diagrama estiverem alinhados, isto significará que a **função não linear** escolhida foi uma “**boa escolha**”.

EXEMPLO 4

□ Gráfico de x versus $Y = \ln y$

k	x_k	y_k	$Y_k = \ln(y_k)$
1	-1	36,547	3,599
2	-0,7	17,264	2,849
3	-0,4	8,155	2,099
4	-0,1	3,852	1,349
5	0,2	1,820	0,599
6	0,5	0,860	-0,151
7	0,8	0,406	-0,901
8	1	0,246	-1,402
Σ	0,3	69,15	8,041

Teste de Alinhamento

□ EXEMPLO 4




Diagrama de dispersão dos novos dados ($Y = \ln y \times X = x$).

EXEMPLO 5

- Usando o Método dos Mínimos Quadrados, ajustar uma curva do tipo $s = q t^p$ aos dados abaixo:

t	2,2	2,7	3,5	4,1
s	65	60	53	50

- Qual o valor de s quando $t = 4,5$?
- Qual o valor de t quando $s = 40$?

EXEMPLO 5

- Caso III: **Função Potencial**

$$s = qt^p$$

- Aplicando logaritmo em ambos os lados:

$$\log s = \log q + p \log t$$

- Realizando as seguintes substituições:

$$Y = \log s$$

$$\alpha_0 = \log q$$

$$\alpha_1 = p$$

$$X = \log t$$

- Obtêm-se: $Y = \alpha_1 X + \alpha_0$

EXEMPLO 5

□ Temos então:

k	t	s	X_k	Y_k	X_k^2	$X_k Y_k$
1	2,2	65	0,3424	1,8129	0,1172	0,6207
2	2,7	60	0,4314	1,7782	0,1861	0,7671
3	3,5	53	0,5441	1,7243	0,2960	0,9382
4	4,1	50	0,6128	1,6990	0,3755	1,0411
Σ			1,9307	7,0144	0,9748	3,3671

EXEMPLO 5

$$\begin{cases} 4\alpha_0 + 1,9307\alpha_1 = 7,0144 \\ 1,9307\alpha_0 + 0,9748\alpha_1 = 3,3671 \end{cases}$$

$$\alpha_0 = 1,963$$

$$\alpha_1 = -0,434$$

$$\alpha_0 = \log q$$

$$\alpha_1 = p$$

$$q = 91,83$$

$$p = -0,434$$

$$s = 91,83 t^{-0,434}$$

EXEMPLO 5

□ Se:

$$s = 91,83t^{-0,434}$$

□ então, para $t = 4,5$; $s \approx 48$, e para $s = 40$; $t \approx 6,8$.

COEFICIENTE DE DETERMINAÇÃO

Coeficiente de Determinação

- O coeficiente de determinação (r^2) nos fornece uma estimativa da qualidade do ajuste.

$$r^2 = \frac{S_t - S_r}{S_t}$$

onde:

- S_t é a soma total dos quadrados dos desvios entre os pontos dados e a média;
- S_r é a soma dos quadrados dos desvios entre o y medido e o y calculado (que chamamos aqui de E).

Coeficiente de Determinação

$$S_t = \sum_{k=1}^m (y_k - \bar{y})^2$$

- S_t mede o quadrado da discrepância entre os dados e uma única estimativa da medida de tendência central – a média.

$$S_r = E = \sum_{k=1}^m [f(x_k) - \phi(x_k)]^2$$

- S_r mede o quadrado da distância vertical entre os dados e uma outra medida da tendência central (a curva ajustada).

Coeficiente de Determinação

- Para implementação computacional, é conveniente usar:

$$r^2 = \left[\frac{m \sum_{k=1}^m x_k y_k - \left(\sum_{k=1}^m x_k \right) \left(\sum_{k=1}^m y_k \right)}{\sqrt{m \sum_{k=1}^m x_k^2 - \left(\sum_{k=1}^m x_k \right)^2} \sqrt{m \sum_{k=1}^m y_k^2 - \left(\sum_{k=1}^m y_k \right)^2}} \right]^2$$

EXEMPLO 6

- Usando os dados do Exemplo 1, obtenha o coeficiente de determinação para o ajuste realizado.
- No Exemplo 1, ajustamos a seguinte reta aos dados:

$$y = 1,538x - 0,360$$

onde:

$$\alpha_0 = -0,360$$

$$\alpha_1 = 1,538$$

EXEMPLO 6

- Para calcular o coeficiente de determinação, precisamos:

k	x_k	y_k	$(y_k - \bar{y})^2$	$\phi(x_k)$	$[y_k - \phi(x_k)]^2$
1	1	1,3	46,24	1,1780	0,0149
2	2	3,5	21,16	2,7160	0,6147
3	3	4,2	15,21	4,2540	0,0029
4	4	5,0	9,61	5,7920	0,6273
5	5	7,0	1,21	7,3300	0,1089
6	6	8,8	0,49	8,8680	0,0046
7	7	10,1	4,00	10,4060	0,0936
8	8	12,5	19,36	11,9440	0,3091
9	9	13,0	24,01	13,4820	0,2323
10	10	15,6	56,25	15,0200	0,3364
Σ	-	-	197,54	-	2,3447

média

$$\bar{y} = 8,1$$

EXEMPLO 6

□ Assim:

$$r^2 = \frac{197,54 - 2,3447}{197,54} = 0,9881$$

- Podemos concluir que a reta se ajustou bem aos dados.
- O coeficiente de determinação indica que a reta explica 98,81% da variação dos dados.

EXEMPLO 7

- Usando os dados do Exemplo 4, obtenha o coeficiente de determinação para o ajuste realizado.
- No Exemplo 4, fizemos um ajuste não-linear. Nestes casos, para calcular o Coeficiente de Determinação (r^2), usamos as informações da equação linearizada:

$$Y = \ln y = \alpha_0 + \alpha_1 X$$

com: $\alpha_0 = 1,099$, $\alpha_1 = -2,5$

EXEMPLO 7

- Como o ajuste será realizado por uma função exponencial é necessário calcular: $Y = \ln y$

k	x_k	y_k	$Y_k = \ln(y_k)$	x_k^2	$x_k Y_k$
1	-1,0	36,547	3,599	1,00	-3,599
2	-0,7	17,264	2,849	0,49	-1,994
3	-0,4	8,155	2,099	0,16	-0,839
4	-0,1	3,852	1,349	0,01	-0,135
5	0,2	1,820	0,599	0,04	0,120
6	0,5	0,860	-0,151	0,25	-0,075
7	0,8	0,406	-0,901	0,64	-0,721
8	1,0	0,246	-1,402	1,00	-1,402
Σ	0,3	69,15	8,041	3,59	-8,645

Exemplo 7

- Para calcular o coeficiente de determinação, precisamos:

k	X_k	Y_k	$(Y_k - \bar{Y})^2$	$\alpha_0 + \alpha_1 X$	$[y_k - (\alpha_0 + \alpha_1 X)]^2$
1	-1,0	3,599	6,7282	3,599	0
2	-0,7	2,849	3,3999	2,849	0
3	-0,4	2,099	1,1966	2,099	0
4	-0,1	1,349	0,1183	1,349	0
5	0,2	0,599	0,1649	0,599	0
6	0,5	-0,151	1,3366	-0,151	0
7	0,8	-0,901	3,6333	-0,901	0
8	1,0	-1,402	5,7943	-1,402	0
Σ	-	-	22,3720	-	0

média
 $\bar{Y} = 1,0051$

Exemplo 7

□ Assim:

$$r^2 = \frac{22,3720 - 0}{22,3720} = 1$$

- Podemos concluir que a função exponencial se ajustou bem aos dados.
- O coeficiente de determinação indica que a função exponencial encontrada explica 100% da variação dos dados.



Regressão Linear Múltipla

Regressão Linear Múltipla

- Em diversas situações, temos uma variável dependente (resposta) que depende de duas ou mais variáveis independentes (explanatórias, preditoras).
- Por exemplo:

$$\phi(x_k) = \alpha_0 + \alpha_1 x_{1k} + \alpha_2 x_{2k}$$

- Vamos, então, minimizar:

$$S_r = \sum_{k=1}^m \left[y_k - (\alpha_0 + \alpha_1 x_{1k} + \alpha_2 x_{2k}) \right]^2$$

Regressão Linear Múltipla

- Para que E seja mínimo é necessário que:

$$\frac{\partial S_r}{\partial \alpha_0} = 0$$

$$\frac{\partial S_r}{\partial \alpha_1} = 0$$

$$\frac{\partial S_r}{\partial \alpha_2} = 0$$

Regressão Linear Múltipla

- Em forma matricial, teremos:

$$\begin{bmatrix} m & \sum_{k=1}^m x_{1k} & \sum_{k=1}^m x_{2k} \\ \sum_{k=1}^m x_{1k} & \sum_{k=1}^m x_{1k}^2 & \sum_{k=1}^m x_{1k}x_{2k} \\ \sum_{k=1}^m x_{2k} & \sum_{k=1}^m x_{1k}x_{2k} & \sum_{k=1}^m x_{2k}^2 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum_{k=1}^m y_k \\ \sum_{k=1}^m x_{1k}y_k \\ \sum_{k=1}^m x_{2k}y_k \end{bmatrix}$$

- Resolvendo este sistema de equações, encontramos os valores de α_0 , α_1 e α_2

Exemplo 8

- Use regressão linear múltipla para ajustar os dados abaixo:

x_1	x_2	y
0,0	0,0	5,0
2,0	1,0	10,0
2,5	2,0	9,0
1,0	3,0	0,0
4,0	6,0	3,0
7,0	2,0	27,0

Exemplo 8

k	y	x_1	x_2	x_1^2	x_2^2	x_1x_2	x_1y	x_2y
1	5,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
2	10,0	2,0	1,0	4,0	1,0	2,0	20,0	10,0
3	9,0	2,5	2,0	6,25	4,0	5,0	22,5	18,0
4	0,0	1,0	3,0	1,0	9,0	3,0	0,0	0,0
5	3,0	4,0	6,0	16,0	36,0	24,0	12,0	18,0
6	27,0	7,0	2,0	49,0	4,0	14,0	189,0	54,0
Σ	54	16,5	14	76,25	54,0	48,0	243,5	100,0

Exemplo 8

□ Teremos então:

$$\begin{bmatrix} 6,0 & 16,5 & 14,0 \\ 16,5 & 76,5 & 48,0 \\ 14,0 & 48,0 & 54,0 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 54,0 \\ 243,5 \\ 100,0 \end{bmatrix}$$

□ Resolvendo o sistema:

$$\alpha_0 = 5,0, \quad \alpha_1 = 4,0 \quad e \quad \alpha_2 = -3,0$$

Exemplo 8

- Após realizar o ajuste, a equação linear de y em função de x_1 e x_2 será:

$$y = 5 + 4x_1 - 3x_2$$

EXEMPLO 8

- Para calcular o coeficiente de determinação, precisamos:

k	$x_{1,k}$	$x_{2,k}$	y_k	$(y_k - \bar{y})^2$	$\phi(x_1, x_2)$	$[y_k - \phi]^2$
1	0,0	0,0	5,0	16	5,0	0,0
2	2,0	1,0	10,0	100	10,0	0,0
3	2,5	2,0	9,0	81	9,0	0,0
4	1,0	3,0	0,0	0	0,0	0,0
5	4,0	6,0	3,0	9	3,0	0,0
6	7,0	2,0	27,0	729	27,0	0,0
Σ	-	-	-	935	-	0,0

$$\text{média} \\ \bar{y} = 9,0$$

$$r^2 = 1$$

Referências

- BURDEN, Richard L.; FAIRES, J. Douglas. **Análise numérica**. São Paulo, SP: Cengage Learning, 2008. xiii, 721 p. ISBN 8522106010.
- RUGGIERO, Marcia A. Gomes; LOPES, Vera Lucia da Rocha. **Cálculo numérico: aspectos teóricos e computacionais**. 2. ed. São Paulo, SP: Makron, c1997. xvi, 406 p. ISBN 8534602042.
- CHAPRA, Steven C.; CANALE, Raymond P. **Métodos numéricos para engenharia**. 5. ed. São Paulo: McGraw-Hill, 2008. 809 p. ISBN 978-85-86804-87-8.